

Sistema Automàtic de Detecció d'Errors en Gimnàstica Artística mitjançant Deep Learning

Lara Castillejo Roig

20 de maig de 2026

Resum– La gimnàstica artística exigeix una precisió biomecànica estricta, avaluada actualment mitjançant el criteri visual humà segons el Codi de Puntuació de la Federació Internacional de Gimnàstica (FIG) o amb infraestructures d'alt cost. Aquest projecte proposa el desenvolupament d'un sistema automàtic i *low-cost* de detecció d'errors tècnics basat en Visió per Computador i *Deep Learning*. Utilitzant models d'estimació de postura (*Pose Estimation*) sobre vídeos monoculars estàndard, el sistema extreu l'esquelet de l'atleta, en calcula els angles de les articulacions i hi aplica les regles de la FIG per estimar les penalitzacions d'execució (*E-Score*). L'objectiu és democratitzar l'anàlisi esportiva, oferint una eina accessible que generi *feedback* visual objectiu per assistir en els entrenaments i competicions nacionals.

Paraules clau– Visió per Computador, Deep Learning, Estimació de Posi, Gimnàstica Artística, Biomecànica, Anàlisi Esportiu

Abstract– Gymnastics demands strict biomechanical precision, currently evaluated through human visual judgment according to the International Gymnastics Federation (FIG) Code of Points or via high-cost infrastructures. This project proposes the development of an automatic, low-cost technical error detection system based on Computer Vision and *Deep Learning*. Using pretrained pose estimation models on standard monocular videos, the system extracts the athlete's skeleton, calculates joint geometry, and applies FIG rules to estimate execution penalties (*E-Score*). The goal is to democratize sport analysis, offering an accessible tool that generates objective visual feedback to assist in training and national competitions.

Keywords– Computer Vision, Deep Learning, Pose Estimation, Gymnastics, Biomechanics, Sports Analytics

1 INTRODUCCIÓ

ELS Jocs Olímpics de París 2024 van evidenciar una problemàtica històrica en la gimnàstica artística: la immensa dificultat d'arbitrar rutines d'alta velocitat de forma exclusivament manual. La polèmica mediàtica sorgida a la final de terra femenina, centrada en la validació del grau de rotació d'un salt acrobàtic per a la Nota de

Dificultat (*D-Score*)[1], va posar de manifest la pressió i la càrrega cognitiva a la qual estan sotmesos els jutges. Si bé en la dificultat existeix una via de reclamació oficial, els jutges depenen exclusivament de la seva agudesesa visual per detectar petits errors biomecànics en fraccions de segon. Aquest factor humà introduït una inevitable subjectivitat en l'avaluació de la Nota d'Execució (*E-Score*) [2]. Aquesta nota avalua exclusivament la perfecció tècnica de l'exercici: parteix d'una base de 10.0 punts sobre la qual els jutges apliquen deduccions per cada error de postura, flexió o aterratge. Es tracta d'una puntuació crítica que, a diferència de la dificultat, és estrictament inalterable segons el reglament.

Tot i que la intel·ligència artificial ja s'utilitza a competicions Olímpiques mitjançant el sistema multimilionari d'escaneig 3D *Judging Support System*, desenvolupat per

• E-mail de contacte: 1641027@uab.cat
• Menció: Computació
• Treball tutoritzat per: Coen Antens (Ciències de la Computació i Intel·ligència Artificial)
• Curs 2025/26

Fujitsu [3], el seu elevat cost el fa inaccessible fora de l'èlit mundial. Això deixa milers de clubs de tecnificació i atletes amateurs sense eines d'anàlisi biomecànica objectives.

2 OBJECTIUS

L'objectiu principal d'aquest projecte és democratitzar l'accés a l'anàlisi esportiva desenvolupant un sistema automàtic de detecció d'errors basat en Visió per Computador de baix cost a partir de vídeos monoculars.

Per tal d'assolir aquesta fita principal, i garantint una anàlisi rigorosa de com els models d'intel·ligència artificial s'adapten a la complexitat de les acrobàcies d'alta velocitat, es defineixen els següents objectius específics:

1. **Auditoria i Selecció de l'Arquitectura:** Avaluar comparativament l'eficiència de diferents models de *Human Pose Estimation (HPE)* per determinar la seva idoneïtat davant l'oclusió i l'alta velocitat pròpia de les acrobàcies executades per la gimnasta.
2. **Estandardització Temporal i Classificació d'Acrobàcies:** Estructurar i normalitzar un *dataset* d'entrenament mitjançant el retall de les seqüències d'acrobàcies a una longitud temporal fixa de 30 *frames* per alimentar la xarxa neuronal recurrent *Long Short-Term Memory (LSTM)* per a la classificació.
3. **Implementació del Pipeline i Suavitat Temporal:** Integrar el model òptim per extreure l'esquelet *frame a frame*, aplicant tècniques d'interpolació espacial i temporal per eliminar el *jitter* de la xarxa neuronal i assegurar la coherència biomecànica.
4. **Automatització de les Regles de Penalització:** Traduir les normatives geomètriques del Codi de Puntuació de la *FIG* [8] en llindars algorísmics (per exemple, angles màxims de flexió de genolls) per tal d'estimar automàticament les deduccions de l'atleta.
5. **Generació de Feedback Visual i Interfície:** Desenvolupar una aplicació d'assistència al judici que integra una doble visualització (vídeo i esquelet) amb un sistema de codi de colors per ressaltar automàticament les infraccions tècniques, permetent al jutge validar o descartar les deduccions de l'algorisme.

3 ESTAT DE L'ART

La *Human Pose Estimation (HPE)*, o Estimació de Pose Humana) és un camp de la Visió per Computador que té com a objectiu localitzar les articulacions clau, anomenades *keypoints*, del cos humà en imatges o vídeos. La resolució d'aquest problema ha evolucionat molt les darreres dècades gràcies als avenços en el reconeixement de patrons i el *Deep Learning*.

3.1 Història de la HPE

Històricament, la comprensió de la figura humana va començar com la detecció d'objectes tradicional (*Object Detection*), on els sistemes es limitaven a emmarcar l'individu dins d'una capsa delimitadora (*bounding box*). Com

a resposta a la manca d'informació biomecànica d'aquest enfocament, la recerca es va centrar en els mètodes basats en parts (*Part-based models*) [9], que identificaven extremitats de manera independent per després intentar ajuntar-les fins a evolucionar cap a les topologies de punts clau actuals (vegeu la Figura 1).

L'autèntica revolució ha arribat amb les xarxes neuronals profundes, que permeten localitzar directament les coordenades espacials (x, y) de cada articulació [10], un salt tecnològic impulsat inicialment per arquitectures pioneres com *DeepPose* [11].




Fig. 1: Evolució cronològica i metodològica dels enfocaments de compressió de la figura humana en Visió per Computador: des de la delimitació per regions (*bounding box*) fins a l'extracció anatòmica de *keypoints*.

L'arquitectura exacta d'aquesta sortida depèn de la topologia anatòmica utilitzada: d'una banda, el format *COCO* [12] defineix un esquelet bàsic de 17 *keypoints*, mentre que el format *BlazePose* l'expandeix fins als 33 *keypoints*, capturant amb detall les mans i els peus (vegeu la Figura 2).




Fig. 2: Comparativa de les topologies anatòmiques estandarditzades en *Human Pose Estimation (HPE)*. A l'esquerra, l'esquelet *COCO* (17 punts); a la dreta, l'esquelet *BlazePose* (33 punts).

Els models actuals d'extracció es divideixen en tres grans famílies metodològiques:

- **Models Top-Down basats en CNN:** Detecten primer la persona mitjançant una *bounding box* i posteriorment retallen la imatge per estimar-ne els *keypoints*. El màxim exponent actual d'aquesta eficiència és *YOLO* (en concret, *YOLO26x-pose*) [4], que conviu amb alternatives clàssiques com *HRNet* [13] o *AlphaPose* [14].

- **Models basats en Vision Transformers (ViT):** Arquitectures recents com *Sapiens-2B* [5] de *Meta* o models previs com *ViTPose* [15] processen la imatge de manera global mitjançant mecanismes d'atenció, eliminant la necessitat de retallades prèvies i entenent millor les postures complexes.
- **Solucions basades en Grafs i Seguiment Temporal:** Frameworks com *MediaPipe BlazePose* [7] incorporen filtres temporals que prediuen la posició basant-se en la inèrcia del *frame* anterior per garantir la coherència del moviment.

3.2 Mètriques d'Avaluació: L'indicador OKS

Per mesurar la precisió d'aquests models no es pot utilitzar una distància euclidiana simple, ja que cada articulació té una rellevància i una dificultat de detecció diferent (per exemple, és més fàcil detectar una espatlla que un turmell). Per això, l'estàndard actual és l'*Object Keypoint Similarity (OKS)* [16], que es defineix com:

$$OKS = \frac{\sum_i \exp(-d_i^2 / 2s^2 k_i^2) \delta(v_i > 0)}{\sum_i \delta(v_i > 0)} \quad (1)$$

On d_i és la distància euclidiana entre el punt predit i el real, s és el factor de normalització basat en l'àrea que ocupa la persona en la imatge, i k_i és una constant específica per a cada tipus d'articulació. Com s'il·lustra a la Figura 3, l'OKS defineix un radi d'acceptació al voltant de cada *keypoint* real, on la penalització per desviació es pondera segons la naturalesa de l'articulació.

Keypoint	k_i
hips	0.107
ankles	0.089
knees	0.087
shoulders	0.079
elbows	0.072
wrists	0.062
ears	0.035
nose	0.026
eyes	0.025




Fig. 3: Representació visual del càlcul de l'OKS. Es defineixen els diferents radis de tolerància segons l'articulació (k_i) escalats per la mida de la persona (s). Imatge de referència adaptada de [16].

Aquesta mètrica permet calcular el *mean Average Precision (mAP)* i es relaciona amb indicadors de distància clau com el *PCK* [17], que són els valors que comparem en les auditories de models d'aquest projecte.

3.3 Fonaments del Suavitat Temporal: Filtre Savitzky-Golay

En l'extracció de poses *frame a frame*, el soroll de la predicció pot generar vibracions artificials (*jitter*). Per solucionar-ho, s'utilitzen filtres de suavitzat temporal, sent el filtre de

Savitzky-Golay [18] un dels més utilitzats en el processament de senyal biomecànic.

L'algorisme realitza un ajust local d'un polinomi de grau k sobre una finestra de dades de mida senar $n = 2m + 1$. Aquest polinomi $p(i)$ es defineix matemàticament com:

$$p(i) = \sum_{j=0}^k c_j i^j \quad (2)$$

L'objectiu del filtre és determinar precisament aquests coeficients c_j per tal de minimitzar l'error quadràtic mitjà (E) respecte a les coordenades originals x_i dins de la finestra temporal:

$$E = \sum_{i=-m}^m w_i (p(i) - x_i)^2 \quad (3)$$

On w_i representa el pes assignat a cada punt. Aquesta minimització optimitza la propagació de la variància $\sigma_{\Delta e}^2$ a través dels coeficients del filtre, assegurant que el suavitzat no elimini la informació clau del moviment. Aquesta operació aconsegueix suavitzar la trajectòria de les articulacions sense eliminar els moviments reals d'alta velocitat de la gimnasta.

3.4 Xarxes Recurrents i Arquitectura LSTM

Per classificar seqüències d'acrobàcies en vídeos, les xarxes neuronals estàndard no serveixen perquè no poden tractar dades seqüencials. Per això s'utilitzen les Xarxes Neuronals Recurrents (*RNN*), que mantenen un estat ocult que actua com a memòria històrica dels *frames* anteriors.

Dins d'aquestes, les xarxes *Long Short-Term Memory (LSTM)* [19] són les més eficaces perquè evitin que la informació es perdi en seqüències llargues. Com es mostra a la Figura 4, un bloc LSTM controla el flux d'informació mitjançant tres portes:

- **Forget Gate (F_t):** Decideix quina informació antiga ja no és important i s'ha d'esborrar.
- **Input Gate (I_t):** Tria quins nous detalls de la postura actual s'han de guardar a la memòria.
- **Output Gate (O_t):** Filtra la informació acumulada per decidir quina és la predicció de l'acrobàcia en aquell instant.

Aquest mecanisme de portes permet que la xarxa aprengui patrons seqüencials complexos, ignorant el soroll i centrant-se en l'evolució de l'esquelet durant el salt.




Fig. 4: Arquitectura d'un bloc recurrent LSTM, on es detalla el flux temporal controlat per les *Forget Gate* (F_t), *Input Gate* (I_t), *Output Gate* (O_t) i la cel·la de memòria candidat ($\tilde{C}_t$).

4 METODOLOGIA

El desenvolupament d'aquest projecte segueix una metodologia que combina la gestió de processos àgils amb una selecció tecnològica orientada a la Visió per Computador.

4.1 Metodologia de Desenvolupament

La gestió del projecte segueix una metodologia àgil basada en el sistema *Kanban*, un enfocament iteratiu que aporta la flexibilitat necessària per adaptar-se als reptes tècnics i facilitar el testeig continu del codi. Com a eina central s'utilitza la plataforma *Notion*, on s'estructura el flux de treball en estats de seguiment ("Per fer", "En curs", "Finalitzat").

L'execució es divideix en fases seqüencials, aplicant la regla estricta de complir totes les tasques d'una iteració abans d'avançar a la següent. Així mateix, aquesta plataforma centralitza la gestió documental i el seguiment temporal mitjançant el diagrama de *Gantt*, garantint un control rigorós dels terminis acadèmics.

4.2 Metodologia Tècnica

L'ecosistema tecnològic es fonamenta en *Python* sota una arquitectura modular que separa la visió, la geometria i la interfície. El nucli empra *PyTorch* per a la inferència del model *Sapiens-2B* i l'entrenament de la xarxa *LSTM*, juntament amb *OpenCV* com a motor de visió per al tractament d'imatge i la renderització vectorial de l'esquelet.

Per al processament numèric i l'estabilització del senyal mitjançant el filtre de *Savitzky-Golay*, s'ha utilitzat *SciPy*, recolzant-se en *NumPy* i *Pandas*. Finalment, l'eina gràfica interactiva per al jutge es desenvolupa amb *PyQt6*.

Amb l'objectiu de garantir la transparència i la reproduïbilitat del sistema, el codi font complet s'ha centralitzat en un repositori públic de GitHub: <https://github.com/laranyeta/gymnastics-error-detection..>

5 PLANIFICACIÓ

L'arquitectura del sistema i la planificació temporal s'han estructurat de manera conjunta en cinc fases seqüencials.

Aquesta planificació fusiona les etapes d'extracció, processament de dades i disseny predictiu amb les fites d'avaluació continuada requerides per l'assignatura. Actualment, el projecte ha completat amb èxit la Fase 3 i es troba en ple desenvolupament de la Fase 4, complint amb els terminis establerts al cronograma original.

- **Fase 1: Recerca i Viabilitat:** Definició de l'abast i comprensió del domini biomecànic. Estudi de l'Estat de l'Art en *Human Pose Estimation (HPE)*. (Fase finalitzada).
- **Fase 2: Implementació Base i Avaluació de Models:** Extracció robusta de coordenades amb *Sapiens-2B*. A nivell de processament de senyal, s'ha implementat la interpolació espacial i el filtre *Savitzky-Golay* per corregir el *frame dropping* detectat en zones de baixa confiança, assegurant l'estabilitat de l'esquelet. (Fase finalitzada).
- **Fase 3: Entrenament de Dades i Lògica:** Etapa nuclear finalitzada amb èxit. S'ha realitzat el *data augmentation*, l'entrenament de la xarxa *LSTM* per a la classificació d'acrobàcies i la implementació del motor de lògica de penalitzacions basat en el Codi de Puntuació de la *FIG*. (Fase finalitzada).
- **Fase 4: Interfície i Validació:** Desenvolupament de l'aplicació interactiva amb *PyQt6* i el sistema de doble visualització (vídeo original i esquelet aïllat). S'ha implementat la *sliding window* per a l'avaluació de rutines completes. (Fase actualment en execució).
- **Fase 5: Tancament i Defensa:** Etapa final reservada per a la consolidació del codi, la redacció de la memòria final en format d'article acadèmic i la preparació de la defensa oral davant del tribunal.

Al desglossament de l'Apèndix B es detalla la temporalitat d'aquestes fases a través de la Taula 5, la distribució de les quals es complementa de forma visual mitjançant el diagrama de *Gantt*.

6 DESENVOLUPAMENT

Aquesta secció detalla l'execució tècnica del projecte, estructurada en el *pipeline* complet de processament, des de l'estandardització de les dades fins al disseny conceptual de la interfície d'usuari.

6.1 Arquitectura de Programari i Estructura de Mòduls

Per garantir la mantenibilitat, l'escalabilitat i una correcta separació de conceptes (*separation of concerns*), el projecte s'ha dissenyat seguint una arquitectura modular. Com es detalla a l'Apèndix A, aquesta organització separa completament les tasques d'inferència de xarxes neuronals profundes, el processament geomètric de senyal i la representació gràfica de la interfície d'usuari.

6.2 Estandardització de l'Esquelet: Migració de Keypoints

Un cop seleccionat *Sapiens-2B* com a motor d'extracció, decisió justificada per l'estudi de viabilitat empíric que es detalla a la Secció 7.1, es va haver de resoldre un repte d'enginyeria crucial relacionat amb l'estructura de dades de l'esquelet virtual. El codi de processament geomètric i d'avaluació de l'*E-Score* s'havia començat a desenvolupar inicialment utilitzant la llibreria *MediaPipe*.

La problemàtica radicava en la divergència de formats d'anotació (*topologies*):

- **COCO (Format Sapiens):** El model estàndard de Sapiens utilitza la topologia COCO de 17 *keypoints*. El principal inconvenient és la manca de punts de control als peus, elements biomecànics indispensables per avaluar l'obertura parabòlica en els salts (*split* o *straddle*) o les penalitzacions d'aterratge. D'altra banda, existeix la variant *COCO WholeBody* de 133 *keypoints*, un volum excessiu de dades que augmentaria els temps d'entrenament de la *RNN* i de còmput.
- **Topologia MediaPipe:** Aquesta topologia utilitza una estructura de 33 *keypoints*. Aquesta solució és ideal per al projecte, ja que inclou els peus (talons i puntes) i manté un volum de dades assequible per al processament seqüencial.

Davant d'aquest escenari, es va descartar l'opció de retallar l'avaluació als 17 *keypoints* o saturar el sistema amb els 133 punts de *WholeBody*. La solució adoptada va consistir a desenvolupar un codi de programari per realitzar una migració i mapeig de topologies (vegeu la Figura 2 a l'Estat de l'Art).

En rebre el JSON amb les coordenades normalitzades de Sapiens, s'executa una funció de mapeig que s'encarrega d'identificar els *keypoints* de COCO i reescriure'ls en les posicions corresponents de la topologia de *MediaPipe*, generant un nou esquelet normalitzat. Aquest pas d'estandardització ha estat la clau per aprofitar la precisió del model *Sapiens-2B* enlloc d'haver de reescriure tota la lògica d'avaluació geomètrica inicialment programada, garantint un esquelet de 33 punts de control (peus inclosos).

6.3 Pipeline d'Extracció i Suavitza Temporal

Un cop seleccionat el model *Sapiens-2B* com a motor principal d'extracció, s'ha implementat el mòdul de processament de senyal per reduir el soroll de l'estimació espacial. L'aplicació pràctica del filtre de *Savitzky-Golay* va generar un dubte tècnic important durant les primeres fases del projecte.

A causa dels primers assajos obtinguts en els girs de perfil (vegeu la Figura 5), es va valorar la possibilitat de suprimir-lo de l'arquitectura. En moviments on la gimnasta experimenta una alta freqüència de rotacions o auto-oclusions severes, l'ajust del polinomi tendia a difuminar l'intercanvi ràpid de cames, provocant un efecte de sobre-suavitza (*oversmoothing*) que deformava la morfologia de l'esquelet real.




Fig. 5: Exemple d'efecte de sobre-suavitza (*oversmoothing*) identificat al *frame* 44 d'un video de prova en un gir de perfil (dreta) respecte a l'esquelet original (esquerra).

No obstant això, aquesta decisió es va revertir en comprovar la seva gran importància per a l'estabilitat global del *pipeline*. Durant les extraccions massives de vídeos per al *dataset*, s'ha demostrat que el filtre és una eina fonamental per contrarestar el *frame dropping* (instants on la xarxa neuronal no detecta cap esquelet). En seqüències d'acrobàcies d'extensió fluida, l'ajust polinòmic assoleix un alineament biomecànic quasi perfecte (vegeu la Figura 6), garantint un senyal continu i net.




Fig. 6: Comportament òptim del filtre en un salt parabòlic, captat al *frame* 13 d'un dels vídeos de prova. L'esquelet corregit (dreta) presenta una continuïtat i estabilitat superior al resultat en cru del model (esquerra).

6.4 Creació del Dataset i Classificació Recurrent

Per construir el *dataset* d'entrenament, s'han seleccionat vídeos del canal oficial de *USA Gymnastics* [21], seguint la taxonomia de bases de dades com *FineGym* [22]. S'ha aïllat la fase aèria a la barra d'equilibris de quatre categories acrobàtiques (vegeu la Figura 7), obtenint una mostra inicial de 72 seqüències.



Fig. 7: Representació de les quatre categories de salts analitzades. D'esquerra a dreta: Tuck (salt agrupat); Pike (salt carpat); Split (salt amb obertura lateral); Straddle (salt amb obertura frontal).

Per millorar la generalització del model donat aquest vo-

lum limitat, s'ha aplicat una tècnica de *Data Augmentation* basada en l'efecte mirall (*mirroring*). En lloc d'editar el vídeo, l'algorisme inverteix directament l'eix X de les coordenades JSON respecte al centre del tors. Això ensenya a la xarxa la simetria de l'exercici i permet duplicar les dades exactament, assolint un *dataset* final de 144 mostres equilibrades.

Aquestes seqüències s'han estandarditzat a blocs de 30 *frames* per entrenar el classificador *LSTM* mitjançant *PyTorch*. El model rep un vector d'entrada amb les coordenades bidimensionals dels 33 *keypoints* normalitzats i, després de processar la seqüència, transmet el darrer estat ocult a una capa lineal de sortida amb activació *Softmax* per estimar la probabilitat de cada classe acrobàtica.

6.5 Motor de Lògica d'Avaluació i Pelvis Virtual

Una vegada la xarxa *LSTM* ha classificat l'acrobàcia, el sistema transfereix el control al mòdul *AcrobaticEvaluator*. Aquest component s'encarrega d'aplicar estrictament les normatives del Codi de Puntuació de la *FIG* [8] en regles geomètriques computables.

Per garantir una avaluació robusta davant la distorsió de la perspectiva monocular, s'ha dissenyat la Pelvis Virtual (vegeu la Figura 8). Si es calculés l'angle directament entre les cames i la pelvis sense processament previ, el sistema només obtindria l'angle relatiu de cada cama per separat, provocant resultats distorsionats segons la posició de la gimnasta respecte a la càmera. La Pelvis Virtual resol aquest problema convertint els vectors d'extrems en un sol angle d'obertura real basat en un punt de control centralitzat.

Aquest punt, que anomenarem punt imaginari (P_i), es calcula com el punt mig geomètric entre els *keypoints* dels malucs esquerre ($P_L = (x_L, y_L)$) i dret ($P_R = (x_R, y_R)$):

$$P_i = \left(\frac{x_L + x_R}{2}, \frac{y_L + y_R}{2} \right) \quad (4)$$

Aquest P_i permet establir un origen de coordenades propi de la gimnasta, invariant a la rotació de l'atleta o a l'angle de gravació.




Fig. 8: Validació geomètrica de l'angle d'obertura en un salt *Split*. Es visualitzen els vectors $\vec{u}$ i $\vec{v}$ definits des del punt central de la Pelvis Virtual (P_i) pintats sobre la pose detectada.

Per calcular l'amplitud d'obertura, el sistema construeix dos vectors, $\vec{u}$ i $\vec{v}$, que connecten aquest punt virtual amb les articulacions dels genolls (K_L i K_R):

$$\vec{u} = K_L - P_i, \quad \vec{v} = K_R - P_i \quad (5)$$

L'angle real d'obertura θ s'obté mitjançant el producte escalar entre ambdós vectors:

$$\theta = \arccos \left(\frac{\vec{u} \cdot \vec{v}}{|\vec{u}| |\vec{v}|} \right) \cdot \frac{180}{\pi} \quad (6)$$

Per adaptar la perfecció teòrica (com els 180° d'un *split*) a la variabilitat biomecànica real, s'han definit uns llindars de penalització específics (vegeu la Taula 1). Com a norma transversal, s'hi suma l'avaluació de l'extensió dels turmells (*ankles*), amb un límit fix de 130° per aplicar exclusivament deduccions *Minor* (-0.1).

TAULA 1: LLINDARS ANGULARS I DEDUCCIONS APLICADES (*E-Score*)

Acrobàcia	Criteri	Minor	Medium	Severe
		(-0.1)	(-0.3)	(-0.5)
Tuck	<i>Hip</i>	< 65°	< 90°	< 100°
	<i>Knee</i>			
Pike	<i>Hip</i>	< 65°	< 90°	< 100°
	<i>Knee</i>	> 170°	> 160°	> 145°
Split	<i>Opening</i>	> 170°	> 160°	> 135°
	<i>Knee</i>	> 170°	> 160°	> 145°
Straddle	<i>Opening</i>	> 170°	> 160°	> 135°
	<i>Knee</i>	> 170°	> 160°	> 145°

El sistema calcula les desviacions al *peak frame*, les resta de la nota base de 10.0 punts, i les visualitza a la interfície amb un codi de colors intuïtiu: verd (*Minor*), taronja (*Medium*) i vermell (*Severe*), facilitant-ne la validació al jutge humà.

6.6 Avaluació Contínua i Mapeig Espacial

Per anar més enllà de l'anàlisi de clips aïllats i permetre el processament de rutines completes, s'ha implementat un algorisme de finestra lliscant (*sliding window*). Aquest sistema fragmenta el flux continu de vídeo in blocs temporals de $N = 30$ *frames* amb un desplaçament constant. Cada bloc s'envia a la xarxa *LSTM*, que retorna una probabilitat de pertinença a les classes acrobàtiques.

Un repte detectat en aquesta fase d'avaluació contínua és la detecció de falsos positius en segments de transició, especialment durant els aterratges (*landings*). Atès que el *dataset* d'entrenament inclou la fase final del salt per captar la biomecànica completa, el model pot classificar erròniament el contacte amb la barra com a part de l'acrobàcia. Aquesta limitació es podria solucionar en treballs futurs amb la creació d'una nova classe a classificar per la xarxa neuronal, com ara "*Transition*", dissenyada específicament per captar els instants on la gimnasta inicia o finalitza el contacte amb l'aparell. És important destacar que el sistema s'ha concebut com una eina d'assistència al judici: el jutge

humà manté el criteri final i pot descartar aquelles avaluacions automàtiques que corresponguin a *frames* no rellevants biomecànicament.

D'altra banda, per visualitzar les penalitzacions de forma clara, s'ha resolt el repte del mapeig espacial de coordenades. Les dades emmagatzemades al JSON són valors normalitzats relatius al centre del tors (en un rang aproximat de $[-1, 1]$), un format optimitzat per a l'aprenentatge del model de classificació profunda però no apte per a la representació gràfica directa. Per resoldre-ho, s'ha definit un llenç de representació normalitzat i s'ha implementat una funció de desnormalització lineal:

$$X_{pixel} = (x_{norm} \cdot S) + O_x, \quad Y_{pixel} = (y_{norm} \cdot S) + O_y \quad (7)$$

On S és un factor d'escala constant per amplificar la magnitud de l'esquelet i (O_x, O_y) representen l'*offset* necessari per centrar la figura en el pla bidimensional. Aquesta transformació permet reconstruir l'esquelet virtual amb una proporció biomecànica perfecta, facilitant la il·luminació dinàmica dels *joints* infractors (verd, taronja i vermell) segons la gravetat de la deducció calculada pel motor.

6.7 Prototipatge de la Interfície Gràfica (GUI)

Com a avançament estratègic de la Fase 4 del cronograma, dedicada a la integració a l'aplicació d'escriptori per als jutges, s'ha iniciat el disseny de la interfície mitjançant el *framework PyQt6*. Aquest mòdul es troba actualment en una fase de prototipatge visual no funcional, servint com a guia conceptual per validar la distribució d'elements abans de la seva implementació lògica final.

L'arquitectura prevista per a la interfície es fonamenta en un sistema de doble visualització (*Dual Viewport*):

- **Panell de Referència i Control:** Està destinat a la visualització del flux de vídeo principal. Es preveu que l'usuari pugui alternar dinàmicament entre dues modalitats crítiques: l'output directe del model *Sapiens* (esquelet en cru renderitzat sobre el fitxer .avi) o la representació avançada que integra el codi de colors segons la gravetat de cada angle biomecànic obtingut de les metadades JSON.
- **Panell d'Anàlisi Biomecànic:** En aquest espai es renderitzarà l'esquelet virtual sobre el llenç linealitzat. Aquesta vista aïllada permet identificar les infraccions posturals de forma neta, utilitzant la il·luminació dinàmica de les articulacions per ressaltar les deduccions detectades pel motor de regles.

Així mateix, s'ha dissenyat un prototip d'aplicació d'escriptori (vegeu la Figura 9) que, en versions futures, comunicarà els resultats del motor de lògica en temps real. L'aplicació prioritza de forma paral·lela la visualització del *frame* actual del vídeo i la llegibilitat en forma de *log* de registre asíncron per a les deduccions aplicades en aquell instant concret del salt. La versió preliminar programada al *framework PyQt6* es pot visualitzar a l'Apèndix C, on es reflexa l'estat actual de l'aplicació.




Fig. 9: Disseny conceptual (*mockup*) de la interfície gràfica dissenyada a Canva.

Això reafirma el disseny del projecte com una eina d'assistència: la interfície es concep perquè la intel·ligència artificial actuï com un observador extern que proposa correccions, deixant sempre la potestat final de confirmar o descartar les penalitzacions al criteri expert del jutge humà.

7 RESULTATS I DISCUSSIÓ

Aquesta secció presenta la validació experimental del sistema, iniciant amb la comparativa de viabilitat dels models d'extracció i seguint amb l'avaluació quantitativa i qualitativa del classificador recurrent i el motor de puntuació biomecànica sobre rutines reals.

7.1 Resultats de l'Estudi de Viabilitat de Models HPE

Per determinar quina de les arquitectures d'estimació de pose era la més adient per a les exigències de la gimnàstica artística, es va dur a terme un estudi preliminar dividit en dues fases: una avaluació en condicions genèriques i una validació en el domini específic del projecte.

En la primera fase, s'ha avaluat el rendiment teòric dels models sobre una mostra d'un *dataset* bàsic exportat de *Roboflow*, amb anotacions sobre subjectes practicant *running*. S'ha seleccionat aquest conjunt per la linealitat de les postures, garantint un entorn neutral per mesurar la precisió base. Els resultats de la Taula 2 reflecteixen el rendiment en aquestes condicions estàndard.

TAULA 2: AVALUACIÓ PRELIMINAR SOBRE EL DATASET DE *running*

Model	mAP@0.5	mAP@0.75	PCK@0.2
YOLO26x-pose	67.7%	46.2%	88.8%
MediaPipe BlazePose	59.5%	39.3%	81.7%
Sapiens-2B	50.6%	34.5%	76.4%

No obstant això, el rendiment en entorns controlats no es tradueix directament en eficàcia dins d'un domini caracteritzat per l'alta velocitat i la complexitat postural. En la segona fase es va realitzar una prova empírica sobre un fragment de rutina real a la barra d'equilibris. Mitjançant *CVAT*[20], es va generar un *Ground Truth* manual dels 84 *frames* de la seqüència de prova (vegeu la Taula 3).

TAULA 3: AVALUACIÓ SOBRE FRAGMENT ACROBÀTIC EN BARRA D'EQUILIBRIS

Model	mAP@0.5	mAP@0.75	PCK@0.2
YOLO26x-pose	19.2%	9.3%	44.0%
MediaPipe BlazePose	13.4%	6.9%	35.4%
Sapiens-2B	36.6%	19.2%	72.7%

L'anàlisi comparativa justifica l'elecció final de *Sapiens-2B*. Mentre que *YOLO26x-pose* lidera el banc de proves genèric, pateix una caiguda severa al domini gimnàstic (el seu *mAP@0.5* baixa fins al 19.2%). Això demostra que les oclusions i inversions penalitzen greument les arquitectures *Top-Down*. En contraposició, l'enfocament de *Vision Transformers* de *Sapiens-2B* demostra una comprensió estructural global superior, retenint un *PCK@0.2* del 72.7% que garanteix la continuïtat de l'esquelet.

7.2 Rendiment del Classificador Recurrent (LSTM)

Per avaluar la capacitat de la xarxa *LSTM* per discriminar entre les quatre categories acrobàtiques (*Pike*, *Split*, *Straddle*, *Tuck*), es va separar el *dataset* final (144 mostres) en un 80% d'entrenament i un 20% de test independent. El rendiment del model s'ha mesurat mitjançant les mètriques clàssiques de Visió per Computador: Precisió (*Precision*), Sensibilitat (*Recall*) i la puntuació *F1-Score*.

A la Taula 4 es detalla el comportament del classificador. Els resultats demostren una alta fiabilitat general, especialment en les classes *Tuck* i *Pike*, on la morfologia de l'esquelet és molt diferent de la resta.

TAULA 4: MÈTRQUES DE RENDIMENT DE L'ARQUITECTURA LSTM PER CLASSE

Categoria	Precision	Recall	F1-Score
<i>Pike</i>	100.0%	100.0%	100.0%
<i>Split</i>	75.0%	33.0%	46.0%
<i>Straddle</i>	33.0%	75.0%	46.0%
<i>Tuck</i>	100.0%	100.0%	100.0%
Mitjana Ponderada	83.0%	76.0%	76.0%

Per analitzar on s'equivoca el model, s'ha generat la matriu de confusió (vegeu la Figura 10). Els indicadors numèrics corroboren de manera empírica la hipòtesi plantejada a la metodologia: el principal repte de la xarxa recau en la confusió entre les classes *Split* i *Straddle* (amb un *F1-Score* simètric del 46.0%). Aquest comportament és biomecànicament lògic, ja que ambdues acrobàcies impliquen una obertura de cames propera als 180° i el model basat en vídeo monocular pateix per distingir la direcció de l'obertura a causa de la pèrdua de profunditat a la perspectiva lateral.

Com a millora futura, la incorporació d'una característica addicional d'orientació (*orientation*), que complementi les mètriques actuals de posició, velocitat, acceleració i angles dins del vector d'entrada de la *LSTM*, ajudaria a solucionar aquest problema, aportant al classificador el context espacial necessari per distingir amb precisió el pla del salt.




Fig. 10: Matriu de confusió del model LSTM sobre el conjunt de test. Es manifesta la lleugera confusió entre les classes d'obertura aèria.

7.3 Validació de l'E-Score i Anàlisi de Casos Gràfics

Una vegada validada la classificació, es va testear la precisió del motor de lògica determinista sobre seqüències reals d'alta velocitat per avaluar l'aïllament de l'esquelet i el comportament del sistema de deduccions basat en el Codi de Puntuació de la FIG. L'experimentació ha permès identificar dues tipologies de resultats:

7.3.1 Funcionament Òptim i Captura de Peak Frame

La Figura 11 exemplifica el comportament ideal del *pipeline*. El model *LSTM* classifica correctament l'acrobàcia i el mòdul d'avaluació localitza amb precisió el *frame* de màxima amplitud. El panell d'anàlisi biomecànic dibuixa l'esquelet net on s'imprimeixen el tipus de salt i la seva confiança. A més, gràcies a l'algorisme de dibuix per capes, s'il·luminen correctament en color vermell aquelles línies de control que superen els llindars crítics (penalització *Severe*), garantint una visualització immediata per al jutge.




Fig. 11: Visualització d'un cas d'èxit. L'esquelet es renditza sobre el llenç reflectint de forma correcta les obertures angulars i superposant amb èxit el color de la penalització més greu.

7.3.2 Propagació de l'Error per Fals Positiu de Transició

Per contra, la Figura 12 mostra un error de detecció causat per les limitacions temporals discutides. En aquest escenari, la xarxa *LSTM* genera un fals positiu en classificar un fragment de transició (l'aterratge de la gimnasta) com una classe acrobàtica activa.

És important matisar que el motor geomètric de l'*AcrobaticEvaluator* actua de forma analíticament correcta: calcula els vectors sobre l'esquelet rebut i, en detectar angles completament tancats o deformats per l'impacte amb l'aparell, aplica de manera coherent una deducció de caràcter *Severe* (-0.5). Per tant, la fallada no recau en la lògica matemàtica de les regles (que executa correctament el codi de colors vermell), sinó en una classificació errònia d'origen temporal.




Fig. 12: Visualització d'un cas crític de fals positiu. S'observa l'aplicació d'una penalització severa provocada per una activació errònia de la LSTM durant la fase de recepció o contacte amb la barra.

7.4 Anàlisi de l'Avaluació Contínua i Eficiència Temporal

L'algorisme de finestra lliscant (*sliding window*) permet processar rutines completes de forma contínua i sense segmentació manual. Davant d'anomalies puntuals com els falsos positius en els aterratges (Figura 12), es reafirma la necessitat d'una eina d'assistència on el jutge humà pugui identificar i invalidar aquestes deduccions a l'instant des de la interfície.

A nivell de rendiment computacional, processar un vídeo d'1 minut i 20 segons (2.400 *frames*) amb una GPU *NVIDIA GeForce RTX 2080 Ti* requereix entre 3 i 4 hores (5-6 segons per *frame*). Aquest cost evidencia el compromís directe entre precisió i velocitat: la complexitat d'utilitzar un model fundacional com *Sapiens-2B* (2 mil milions de paràmetres) genera aquest *bottleneck* temporal, però garanteix la robustesa extrema davant d'oclusions descrita a la Taula 3.

D'aquesta manera, l'execució *offline* esdevé una solució econòmica i assequible per a l'esport base, evitant infraestructures inassolibles com la de *Fujitsu*. Com a línies de treball futur per reduir aquesta latència, es planteja la migració del sistema cap a GPUs modernes de gamma alta (com la *NVIDIA RTX 4090*) o l'exploració de models d'extracció

més lleugers que assoleixin mantenir la precisió anatòmica de la gimnasta.

8 CONCLUSIONS PROVISIONALS

A partir del desenvolupament i les proves de validació realitzades fins a la data, s'ha demostrat la viabilitat tècnica del sistema. Les principals conclusions es resumeixen en els següents punts:

- La combinació del model *Sapiens-2B* com a xarxa recurrent *LSTM* ha demostrat ser una arquitectura robusta per a l'anàlisi cinemàtica. Tot i l'ambigüitat provocada per la pèrdua de profunditat en els salts d'obertura (amb un *F1-Score* del 46.0% en *Split* i *Straddle*), l'èxit absolut del 100% en les classes *Tuck* i *Pike* en valida el rendiment global.
- El disseny de la Pelvis Virtual com a punt de control sintètic ha demostrat ser una solució geomètrica eficaç. L'ús de vectors i productes escalars permet traduir les normatives de la *FIG* de manera totalment objectiva i invariant respecte a la perspectiva lineal o rotació de la gimnasta.
- L'estudi de latència del *pipeline* (entre 3 i 4 hores per a un vídeo de 2.400 *frames* en una GPU *NVIDIA RTX 2080 Ti*) confirma el compromís clàssic entre precisió biomecànica i temps de còmput. No obstant això, l'execució *offline* compleix l'objectiu fonamental de democratitzar aquest tipus d'anàlisi, oferint una alternativa assequible per a l'esport base davant els sistemes multimilionaris de l'elit mundial.
- Es confirma el disseny del programari com una eina d'assistència i suport al judici, on la intel·ligència artificial actua com un observador algorítmic d'alta precisió per proporre deduccions de l'*E-Score*, delegant sempre la decisió final al criteri expert del jutge humà.

Com a línia de treball immediata per a la finalització del projecte, un cop tancada amb èxit la validació dels models lògics i d'intel·ligència artificial, es procedirà al desenvolupament i programació de la interfície gràfica interactiva definitiva mitjançant el *framework PyQt6*.

ÚS DE LA IA GENERATIVA

En compliment de la normativa d'avaluació del Treball Final de Grau de la UAB, es declara que en l'elaboració d'aquest Informe de Progrés II s'han utilitzat eines d'Intel·ligència Artificial generativa (model *Gemini 3.1 Pro*).

D'acord amb les directrius establertes, el seu ús s'ha limitat exclusivament a l'assistència en aspectes formals i tècnics. Concretament, l'eina s'ha emprat per a la revisió ortotipogràfica, la millora de la fluïdesa del text en català, i com a suport tècnic per a la resolució de problemes de formatació i estructuració del codi en llenguatge $\text{\LaTeX}$.

Es certifica que no s'ha utilitzat cap model generatiu per a la creació dels continguts intel·lectuals sotmesos a avaluació. La definició del context, l'establiment dels objectius, el disseny metodològic, la programació i la planificació temporal del projecte han estat elaborats de manera íntegrament autònoma per l'autora.

REFERÈNCIES

- [1] La Vanguardia, *Una gimnasta rumana recibe la medalla de bronce once días después de la final de los JJOO*, Agost 2024. [En línia]. Disponible a: <https://www.lavanguardia.com/deportes/20240817/9874948/gimnasta-recibe-medalla-bronce-once-dias-final-jjoo.html>
- [2] International Olympic Committee (IOC), *Artistic gymnastics scoring system and judging rules: The D-score and E-score explained*. [En línia]. Disponible a: <https://olympics.com/en/news/artistic-gymnastics-scoring-system-judging-rules-e-d-score>
- [3] Fujitsu, *Judging Support System Co-development with FIG*. [En línia]. Disponible a: <https://www.fujitsu.com/global/themes/data-drive/n/judging-support-system/>
- [4] Ultralytics, *YOLOv8 Pose Task Documentation*. [En línia]. Disponible a: <https://docs.ultralytics.com/tasks/pose/#predict>
- [5] T. Rawal et al. (Meta), *Sapiens: Foundation for Human Vision Models*, arXiv preprint arXiv:2408.12569, 2024. Disponible a: <https://arxiv.org/abs/2408.12569>
- [6] Google Research, *MediaPipe: A Framework for Building Perception Pipelines*. Disponible a: <https://arxiv.org/pdf/1906.08172>
- [7] V. Bazarevsky et al. (Google), *BlazePose: On-device Real-time Body Pose tracking*, CVPR Workshop on Computer Vision for Augmented and Virtual Reality, 2020. Disponible a: <https://arxiv.org/abs/2006.10204>
- [8] Fédération Internationale de Gymnastique (FIG), *2025-2028 Code of Points (MAG & WAG)*. [En línia]. Disponible a: <https://www.gymnastics.sport/site/rules/>
- [9] X. Li, Y. Liu, N. Dong, S. Qin, and X. Hu, *PartImageNet++ Dataset: Scaling up Part-based Models for Robust Recognition*, en European Conference on Computer Vision (ECCV), 2024. Disponible a: <https://arxiv.org/abs/2407.10918>
- [10] C. Zheng, W. Wu, C. Chen, T. Yang, S. Zhu, J. Shen, N. Kehtarnavaz, and M. Shah, *Deep Learning-Based Human Pose Estimation: A Survey*, ACM Computing Surveys, vol. 56, no. 1, 2023. Disponible a: <https://arxiv.org/pdf/2012.13392>
- [11] A. Toshev and C. Szegedy, *DeepPose: Human pose estimation via deep neural networks*, en Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1653-1660, 2014. Disponible a: <https://arxiv.org/abs/1312.4659>
- [12] T.Y. Lin et al., *Microsoft COCO: Common Objects in Context*, en European Conference on Computer Vision (ECCV), pp. 740-755, 2014. Disponible a: <https://arxiv.org/abs/1405.0312>
- [13] Microsoft Research, *Deep High-Resolution Representation Learning for Human Pose Estimation*. Disponible a: <https://arxiv.org/pdf/1902.09212>
- [14] Hao-Shu Fang, *AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time*. Disponible a: <https://arxiv.org/pdf/2211.03375>
- [15] ViTAE-Transformer, *ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation*. GitHub. [En línia]. Disponible a: <https://github.com/ViTAE-Transformer/ViTPose>
- [16] D. Maji, S. Nagori, M. Mathew, and D. Poddar, *YOLO-Pose: Enhancing YOLO for Multi Person Pose Estimation Using Object Keypoint Similarity Loss*, en IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2022. Disponible a: <https://arxiv.org/abs/2204.06806>
- [17] Y. Yang and D. Ramanan, *Articulated Human Detection with Flexible Mixtures of Parts*, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 35, no. 12, pp. 2878-2890, 2013. Disponible a: https://www.cs.cmu.edu/~deva/papers/pose_pami.pdf
- [18] Paul W. Oxby, *An Optimal Weighting Function for the Savitzky-Golay Filter*. Disponible a: <https://arxiv.org/pdf/2111.11667>
- [19] C. B. Vennerød, A. Kjærran, and E. S. Bugge, *Long Short-term Memory RNN*, arXiv preprint arXiv:2105.06756, 2021. Disponible a: <https://arxiv.org/pdf/2105.06756>
- [20] CVAT - Open Data Annotation Platform. [En línia]. Disponible a: <https://www.cvat.ai/>
- [21] USA Gymnastics, *USA Gymnastics Official YouTube Channel - Balance Beam Search results*. [En línia]. Disponible a: <https://www.youtube.com/@usagymnastics/search?query=balance%20beam>
- [22] D. Shao et al., *FineGym: A Hierarchical Video Dataset for Fine-grained Action Understanding*. Disponible a: <https://arxiv.org/pdf/2004.06704>

A DIAGRAMA D'ARQUITECTURA MODULAR




Fig. 13: Diagrama complet d'arquitectura de programari i interacció de mòduls del sistema (HPE, RNN, Scoring i GUI). Elaboració pròpia mitjançant *Canva*.

B CRONOGRAMA DE TASQUES I DIAGRAMA DE GANTT




Fig. 14: Cronograma del projecte (Diagrama de Gantt). Elaboració pròpia mitjançant *Canva* a partir de la planificació feta a *Notion*.

TAULA 5: CRONOGRAMA DE TASQUES I FITES D’AVALUACIÓ ACTUALITZAT

Id		Tasca i Fites	Dates
Fase 1: Recerca i Viabilitat			
T1.1		Revisió de l'Estat de l'Art	16/02 - 01/03
T1.2		Estudi de l'abast i domini	20/02 - 04/03
T1.3		Informe Inicial (Fita: 08/03)	01/03 - 08/03
Fase 2: Implementació Base i Avaluació de Models			
T2.1		Avaluació YOLO, MediaPipe, Sapiens	09/03 - 22/03
T2.2		Integració Sapiens i Proc. Senyal	16/03 - 05/04
T2.3		Informe Progrés I (Fita: 12/04)	06/04 - 12/04
Fase 3: Entrenament de Dades i Lògica			
T3.1		Processament de dades i entrenament RNN	13/04 - 03/05
T3.2		Aplicació de la lògica de puntuació (FIG)	04/05 - 17/05
T3.3		Informe Progrés II (Fita: 24/05)	18/05 - 24/05
Fase 4: Interfície i Validació			
T4.1		Generació de l'output visual final (GUI)	25/05 - 05/06
T4.2		Validació i ajustament de la RNN	01/06 - 14/06
T4.3		Proposta Informe Final (Fita: 14/06)	01/06 - 14/06
Fase 5: Tancament i Defensa			
T5.1		Dossier TFG (Fita: 29/06)	15/06 - 29/06
T5.2		Pòster (Fita: 02/07)	22/06 - 02/07
T5.3		Defensa (Fita: 02/07 - 08/07)	29/06 - 08/07

C DESKTOP APPLICATION




Fig. 15: Primer resultat de l'interfície gràfica no funcional creada amb el *framework* *PyQt6*.